

# Estimacion puntual y por Intervalos

## Estimacion Puntual

Sea  $(X_i)_{i=1}^n$  una muestra aleatoria con distribución  $F$ . Denotemos con  $X$  a un elemento con misma distribución que  $X_i$ . Asuma que estamos interesados en estimar la probabilidad de que  $X$  sea mayor a uno:  $(F) := P_F(X > 1)$ .

### Estimador 1:

1.1 Proponga un estimador `somb` consistente para  $(F) = P_F(X > 1)$  (observar que aquí hacemos explícito que depende de la distribución  $F$ ).

```
# tita_somb <- E(xi,xn) (tal que xi sea >1) / n
```

1.2 Implemente una función `estsombrero` que tenga por argumento un conjunto de datos  $(x_1, \dots, x_n)$  muestra y devuelva el valor de la estimación obtenida utilizando `somb`.

```
# 1.2
estimador_tita_somb <-function(datos){
  sum(datos>1)/length(datos)
}

datos <- c(12.23,6.37, 6.10, 0.70, 3.48, 2.82, 9.55, 2.21, 0.72, 9.09)
```

1.3 Calcule el valor de `somb` en el siguiente conjunto de datos utilizando `estsombrero`:

```
#1.3
tita_somb <- estimador_tita_somb(datos)
```

## Mundo Exponencial: Calentando motores

1.4 Sea  $X$  una variable aleatoria con distribución  $F$ , exponencial de parámetro  $\lambda = 0.2$ :  $X \sim E(0.2)$ . Indique el valor de

```
#E(x) = 1/0.2
#V(x)= 1/(0.2)**2
#P(x) = 1-(1-exp(1)**(-0.2*1))

lambda = 0.2
proba <- 1- pexp(1,lambda) # porque la pexp va de -inf a el valor que indico
```

**1.5** Sea ahora  $X$  una variable aleatoria con distribución  $F$  perteneciente a la familia exponencial: es decir,  $X \sim E(\lambda)$  con  $\lambda$  DESCONOCIDO. Expresar cada uno de los siguientes objetos en función de  $\lambda$ :

```
# E(x) = 1/lambda
# V(x) = 1/(lambda)**2
# P(x) = 1-(1-exp(1)**(-lambda*1))

lambdaestimado = 1/mean(datos)
proba <- 1- pexp(1,lambdaestimado) # porque la pexp va de -inf a el valor que indico
```

## Mundo Exponencial: Haciendo Estadística

Sean  $(X_i)_{i=1}^n$  i.i.d., con misma distribución que  $X$ . Asuma ahora que  $F$  pertenece a la familia exponencial; es decir,  $X \sim E(\lambda)$ , con  $\lambda$  DESCONOCIDO.

**1.6** Proponga un nuevo estimador  $\hat{\lambda}$  consistente para  $\lambda(F) = P(X > 1)$  bajo este nuevo escenario. Es decir, defina  $\hat{\lambda} = \hat{\lambda}(X_1, \dots, X_n)$  de forma tal que  $\hat{\lambda} = \hat{\lambda}(X_1, \dots, X_n) \rightarrow \lambda$  cuando  $X_i \sim E(\lambda)$ ,  $n \rightarrow \infty$ .

```
# P(x) = 1-(1-exp(1)**(-lambdaestimado*1))
titarulo <- 1- pexp(1,lambdaestimado)
```

**1.7** Implemente una función `estrulo` que tenga por argumento un conjunto de datos  $(x_1, \dots, x_n)$  y devuelva el valor de la estimación obtenida utilizando `estrulo`.

```
estimador_tita_rulo <- function(df){
  lambdaestim <- 1/mean(df)
  1- pexp(1,lambdaestim)
}
```

**1.8** Calcule el valor de  $\hat{\lambda}$  en el siguiente conjunto de datos utilizando `estrulo`:

```
estrulo <- estimador_tita_rulo(datos)
```

*Simulación 1:* A lo largo de esta simulación generaremos variables con distribución exponencial de parámetro  $\lambda = 0.2$ .

**1.9** Indique cuál es el verdadero valor que estamos queriendo estimar:  $\lambda = P(X > 1)$ , siendo  $X \sim E(0.2)$ .

```
lambda <- 0.2
tita_verdad <- 1- pexp(1,lambda)
```

**1.10** Genere una muestra de tamaño  $n=50$  y calcule los dos estimadores.

```
datitos <- rexp(50,lambda)
```


1.11 Genere  $N_{rep} = 1000$  muestras de tamaño  $n=50$  y guarde los valores de cada uno de los dos estimadores calculados en cada uno de los  $N_{rep} = 1000$  conjuntos de datos.

```
lambda <- 0.2
nrep <- 1000
muchos_est_somb<-rep(NA,nrep)
muchos_est_rulo<-rep(NA,nrep)

for (i in 1:nrep) {
  datitos <- rexp(50,lambda)
  muchos_est_somb[i]<- estimador_tita_somb(datitos)
  muchos_est_rulo[i]<- estimador_tita_rulo(datitos)
}
```

1.12 Realice un histograma de cada uno de los estimadores propuestos con los valores obtenidos en el ítem anterior. Comente los gráficos realizados. Indique que estimador prefiere en este escenario y explique a que atribuye sus bondades.

```
hist(muchos_est_somb,probability = TRUE,breaks = 50,col=3)
hist(muchos_est_rulo,probability = TRUE,breaks = 50,add=TRUE,col = 2)
```



1.13 Represente en una tabla el error cuadrático medio (estimado) de los estimadores rulo y somb para muestras de tamaño  $n=150$ ,  $n=200$ ,  $n=500$  y  $n=1000$ , utilizando  $N_{rep}=1000$  replicaciones en cada caso. ¿Que estimador prefiere bajo este escenario?

```

#VERDAD
set.seed(123)
lambda <- 0.2

#Primer estimador. Tita sombrero
lambda<-0.2
tita_verdad <- 1- pexp(1,lambda)

Nrep<-1000 #Num de replicaciones
n<-c(150,200,500,1000) #Vec con tamanos de las muestras
ecm_sombrero<-rep(NA,length(n))

for (j in 1:length(n)){
  tamano<-n[j] # tamaño de n
  empi_dist_tita<-rep(NA, Nrep)
  diferencia<-rep(NA, Nrep)
  for (i in 1:Nrep){
    #Genero mis datos de tamaño n
    mis_exponenciales<-rexp(tamano,lambda)
    #Para cada replica calculo proba40
    empi_dist_tita[i]<- estimador_tita_somb(mis_exponenciales)
    #Calculo dif entre la estimacion de cada replicacion y la verdad
    diferencia[i]<-((empi_dist_tita[i]-tita_verdad)^2)
  }
  ecm_sombrero[j]<-sum((diferencia)/Nrep)
}

#Segundo estimador. Tita rulo
ecm_rulo<-rep(NA,length(n))
set.seed(123)
for (j in 1:length(n)) {
  tamano<-n[j]
  empi_dist_tita <- rep(NA, Nrep)
  diferencia<-rep(NA, Nrep)
  for (i in 1:Nrep){
    #Genero mis datos de tamaño n
    mis_exponenciales<-rexp(tamano,lambda)
    #Para cada replica calculo proba40 exp con lambda estimado
    empi_dist_tita[i]<-estimador_tita_rulo(mis_exponenciales)
    diferencia[i]<-((empi_dist_tita[i]-tita_verdad)^2)
  }
  ecm_rulo[j]<-sum((diferencia)/Nrep)
}

tabla_errores<-data.frame(n,ecm_sombrero,ecm_rulo)
colnames(tabla_errores)<-c("Tamano muestra","ECM tita sombrero","ECM tita rulo")
tabla_errores

```

```

##   Tamano muestra ECM tita sombrero ECM tita rulo
## 1           150      0.0009777981 1.858914e-04
## 2           200      0.0007538040 1.399692e-04
## 3           500      0.0002867139 5.433339e-05
## 4          1000      0.0001367265 2.678819e-05

```

## Mundo Normal: Ojo al Piojo!

Considere ahora variables aleatorias  $X_i$  i.i.d. con distribución normal de media  $\mu = 1/0.2$  y  $\sigma^2 = 1/0.2^{**2}$   
#### 1.14 Calcule la probabilidad de que  $X_i$  supere el valor 1:  $P(X_i > 1)$

```
mu <- 1/0.2
sigmacuad <- 1/(0.2)**2
sigma <- sqrt(sigmacuad)

proba1_normal <- 1- pnorm(1,mu,sigma)
```

**1.15** Calcule el valor de cada uno de los siguientes límites:  $\lim_{n \rightarrow \infty} \text{somb}(X_1, \dots, X_n) = \dots$ ,  $\lim_{n \rightarrow \infty} \text{rulo}(X_1, \dots, X_n) = \dots$

**1.16** Proponga un nuevo estimador  $\hat{\mu}_n = \hat{\mu}_n(X_1, \dots, X_n)$  para  $\mu(F) = P(F)(X_i > 1)$ , asumiendo ahora que  $F$  pertenece a la normal:  $X_i \sim N(\mu, \sigma^2)$ .

```
mu_estim <- mean(datos)
sigma_estim <- sd(datos)
proba2_normal_estim <- 1- pnorm(1,mu_estim,sigma_estim)
```

*Simulación 2:* A lo largo de esta simulación generaremos variables con distribución normal de media  $\mu = 1/0.2$  y  $\sigma^2 = 1/0.2^{**2}$

Represente en una tabla el error cuadrático medio (estimado) de los estimadores  $\hat{\mu}_n$ ,  $\hat{\sigma}_n$  y  $\hat{\mu}_n$  para muestras de tamaño  $n=150, n=200, n=500$  y  $n=1000$ , utilizando  $N_{rep}=1000$  replicaciones en cada caso. Analice los resultados obtenidos y explique que estimador elegiría bajo este escenario.

```
#VERDAD
set.seed(123)
mu <- 1/0.2
sigmacuad <- 1/(0.2)**2
sigma <- sqrt(sigmacuad)
tita_verdad <- 1- pnorm(1,mu,sigma)

estimador_tita_somb <-function(datos){
  sum(datos>1)/length(datos)
}

estimador_tita_rulo<-function(df){
  lamnbdaestim <- 1/mean(df)
  1- pexp(1,lamnbdaestim)
}

estimador_tita_estrella<-function(datos){
  mu1 <- mean(datos)
  sigma1 <- sd(datos)
  1- pnorm(1,mu1,sigma1)
}

#Primer estimador. Tita sombrero
```

```

Nrep<-1000 #Num de replicaciones
n<-c(150,200,500,1000) #Vec con tamanos de las muestras
ecm_sombrero<-rep(NA,length(n))

for (j in 1:length(n)){
  tamano<-n[j] # tamaño de n
  empi_dist_tita<-rep(NA, Nrep)
  diferencia<-rep(NA, Nrep)
  for (i in 1:Nrep){
    #Genero mis datos de tamaño n
    mis_normales<-rnorm(tamano,mu,sigma)
    #Para cada replica calculo proba
    empi_dist_tita[i]<- estimador_tita_somb(mis_normales)
    #Calculo dif entre la estimacion de cada replicacion y la verdad
    diferencia[i]<-((empi_dist_tita[i]-tita_verdad)^2)
  }
  ecm_sombrero[j]<-sum((diferencia)/Nrep)
}

#Segundo estimador. Tita rulo
ecm_rulo<-rep(NA,length(n))
set.seed(123)
for (j in 1:length(n)) {
  tamano<-n[j]
  empi_dist_tita <- rep(NA, Nrep)
  diferencia<-rep(NA, Nrep)
  for (i in 1:Nrep){
    #Genero mis datos de tamaño n
    mis_normales<-rnorm(tamano,mu,sigma)
    #Para cada replica calculo proba40 exp con lambda estimado
    empi_dist_tita[i]<-estimador_tita_rulo(mis_normales)
    diferencia[i]<-((empi_dist_tita[i]-tita_verdad)^2)
  }
  ecm_rulo[j]<-sum((diferencia)/Nrep)
}

#Tercer estimador. Tita estrella
ecm_estrella<-rep(NA,length(n))
set.seed(123)
for (j in 1:length(n)) {
  tamano<-n[j]
  empi_dist_tita <- rep(NA, Nrep)
  diferencia<-rep(NA, Nrep)
  for (i in 1:Nrep){
    #Genero mis datos de tamaño n
    mis_normales<-rnorm(tamano,mu,sigma)
    #Para cada replica calculo proba40 exp con lambda estimado
    empi_dist_tita[i]<-estimador_tita_estrella(mis_normales)
    diferencia[i]<-((empi_dist_tita[i]-tita_verdad)^2)
  }
  ecm_estrella[j]<-sum((diferencia)/Nrep)
}

```

```

}

tabla_errores<-data.frame(n,ecm_sombrero,ecm_rulo,ecm_estrella)
colnames(tabla_errores)<-c("Tamano muestra","ECM tita sombrero","ECM tita rulo","ECM tita estrella")
tabla_errores

```

```

##   Tamano muestra ECM tita sombrero ECM tita rulo ECM tita estrella
## 1           150      0.0010403933  0.0010655835      0.0006879276
## 2           200      0.0008530688  0.0010427762      0.0005614014
## 3           500      0.0003360081  0.0009587962      0.0002136623
## 4          1000      0.0001578758  0.0009369650      0.0001051160

```

## Estimación por Intervalos

El objetivo de este ejercicio es comparar empíricamente la performance de diferentes intervalos de confianza, basados en estimadores asintóticamente normales. Por un lado, utilizaremos intervalos construidos estimando la varianza asintótica mediante (i) bootstrap y (ii) propagación de errores Finalmente, construiremos (iii) intervalos para una proporción, siendo que el parametro de interes es una probabilidad. Estudiaremos el nivel de cubrimiento empirico y la longitud media de cada uno procedimientos mencionados. Recordemos que el valor de interes es  $\theta = P(X > 1)$ . Generaremos datos asumiendo que provienen de una familia exponencial  $E(\lambda): X \sim E(\lambda)$ , con  $\lambda = 0.2$

1. Obtenga una formula para el parametro de interes en función de  $\lambda$ , que permita calcular la varianza asintótica del estimador en (propuesto en el punto 1.6) utilizando propagacion de errores.

2. Construir los siguientes tres posibles intervalos de confianza asintoticos para el parametro de interes, con nivel 0.95

(a) Intervalos asintoticamente normal basado en  $\hat{p}_n$ , propuesto en el item 1.1, considerando que se trata de un estimador para una probabilidad (es decir, no deja de ser un pb).

```

# Verdad
lambda<-0.2
tita_verdad <- 1- pexp(1,lambda)

# 1.1
estimador_p <-function(datos){
  sum(datos>1)/length(datos)
}

cantidad_intervalos <- 1000
resultados_esta <- c()

for (i in 1:cantidad_intervalos){
  n_exp = 50
  mis_exp <-rexp(n_exp,0.2)
  estimador <-estimador_p(mis_exp)
  error_estimador <- sqrt((estimador*(1-estimador))/length(n_exp))
}

```

```

alfa<-0.05
factor<-qnorm(1-alfa/2)
intervalo_1 <- estimador - factor*error_estimador
intervalo_2 <- estimador + factor*error_estimador
esta<- intervalo_1<=tita_verdad & tita_verdad<=intervalo_2
resultados_esta <- c(resultados_esta,esta)
}
mean(resultados_esta)

```

```
## [1] 1
```

(b) Intervalos asintóticamente normal basado en en, propuesto en el ítem 1.6, estimando la varianza asintótica con propagación de errores.

(c) Intervalos asintóticamente normal basado en en, propuesto en el ítem 1.6, estimando la varianza asintótica con Bootstrap, utilizando  $N_{boot} = 2000$ .

```

lambda<-0.2
tita_verdad <- 1- pexp(1,lambda)

# 1.1
estimador_tita_somb <-function(datos){
  sum(datos>1)/length(datos)
}

cantidad_intervalos <- 1000
resultados_esta <- c()

for (i in 1:cantidad_intervalos){
  n_exp = 100
  lambda = 0.2
  mis_exp <-rexp(n_exp,lambda)
  tita_somb <-estimador_tita_somb(mis_exp)
  # Bootstrap
  nboot<-1000
  remuestreo<-rep(NA,n_exp)
  for (i in 1:nboot){
    datos_estrella<- rexp(n_exp,lambda)
    remuestreo[i]<-estimador_tita_somb(datos_estrella)
  }
  error_varianza<-sqrt(var(remuestreo)) #

  alfa<-0.05
  factor<-qnorm(1-alfa/2)
  intervalo_1 <- tita_somb - factor*error_varianza
  intervalo_2 <- tita_somb + factor*error_varianza
  esta<- intervalo_1<=tita_verdad & tita_verdad<=intervalo_2
  resultados_esta <- c(resultados_esta,esta)
}
mean(resultados_esta)

```

```
## [1] 0.948
```

3. Genere datos utilizando  $\lambda = 0.2$ . Considere  $n = 100, 200, 500$  y estudie el nivel de cubrimiento empírico en  $N_{rep} = 1000$  replicaciones de los intervalos propuestos. Recuerde que el cubrimiento empírico calcula la proporción de veces que el intervalo simulado atrapa al valor de interés.

```
lambda<-0.2
tita_verdad <- 1- pexp(1,lambda)

# 1.1
estimador_tita_somb <-function(datos){
  sum(datos>1)/length(datos)
}

cubrimiento_enes <- c()
enes <- c(100,200,500)
for (n_exp in enes){
  cantidad_intervalos <- 1000
  resultados_esta <- c() # cubrimiento empirico

  for (i in 1:cantidad_intervalos){
    lambda = 0.2
    mis_exp <-rexp(n_exp,lambda)
    tita_somb <-estimador_tita_somb(mis_exp)
    # Bootstrap
    nboot<-500
    remuestreo<-rep(NA,n_exp)
    for (i in 1:nboot){
      datos_estrella<- rexp(n_exp,lambda)
      remuestreo[i]<-estimador_tita_somb(datos_estrella)
    }
    error_varianza<-sqrt(var(remuestreo)) # 1/lambda**2

    alfa<-0.05
    factor<-qnorm(1-alfa/2)
    intervalo_1 <- tita_somb - factor*error_varianza
    intervalo_2 <- tita_somb + factor*error_varianza
    esta<- intervalo_1<=tita_verdad & tita_verdad<=intervalo_2
    resultados_esta <- c(resultados_esta,esta)
  }
  cubrimiento_enes <- c(cubrimiento_enes,mean(resultados_esta))
}

tabla_errores<-data.frame(enes,cubrimiento_enes)
colnames(tabla_errores)<-c("N","Cubrimiento")
tabla_errores
```

```
##      N Cubrimiento
## 1 100      0.963
## 2 200      0.947
## 3 500      0.963
```