


Estimacion no parametrica de la densidad

Ejercicio de clase sobre la empirica


```
datos <- c(0.57, 0.93, 0.81, 0.44,0.36, 0.52,0.65,0.69,0.82,0.12) #los datos son de una uniforme
# datos <- runif(100)
# Empirica devuelve la proba de datos < t
empirica <- function(datos,t){
  mean(datos<=t)
}

ejex <- seq(0,1,0.01)
ejey <- c()
# Recorro cada x y calculo el y
for(i in ejex){
  ejey<- c(ejey,empirica(datos,i))
}

plot(ejex,ejey,cex=0.5)
```



```
# ecdf: Empirical Cumulative Distribution Function
plot(ecdf(datos))
```



Probando ecdf

Parte 1: Estimacion

1 Los datos que se muestran a continuaci3n se hallan en el archivo buffalo.txt y corresponden a la mediciones de cantidad de nieve ca3da (en pulgadas) en Buffalo en los inviernos de 1910/1911 a 1972/1973.


Realice un histograma para estos datos utilizando los par3metros por default. Repetir eligiendo como puntos de corte las siguientes secuencias: i) de 20 a 140 con paso 10 ii) de 20 a 140 con paso 5. Comparar los tres histogramas obtenidos. ¿Tiene algun efecto el refinamiento de los bins?

```
# datos = scan(nlines = 4)
# 126.4 82.4 78.1 51.1 90.9 76.2 104.5 87.4 110.5 25.0 69.3 53.5 39.8 63.6 46.7 72.9 79.6 83.6 80.7
# 60.3 79.0 74.4 49.6 54.7 71.8 49.1 103.9 51.6 82.4 83.6 77.8 79.3 89.6 85.5 58.0 120.7 110.5 65.4
# 39.9 40.1 88.7 71.4 83.0 55.9 89.9 84.8 105.2 113.7 124.7 114.5 115.6 102.4 101.4 89.8 71.5 70.9 98.3

datos = c(
126.4, 82.4, 78.1, 51.1, 90.9, 76.2, 104.5, 87.4, 110.5, 25.0, 69.3, 53.5, 39.8, 63.6, 46.7, 72.9, 79.6, 83.6, 80.7,
60.3, 79.0, 74.4, 49.6, 54.7, 71.8, 49.1, 103.9, 51.6, 82.4, 83.6, 77.8, 79.3, 89.6, 85.5, 58.0, 120.7, 110.5, 65.4,
39.9, 40.1, 88.7, 71.4, 83.0, 55.9, 89.9, 84.8, 105.2, 113.7, 124.7, 114.5, 115.6, 102.4, 101.4, 89.8, 71.5, 70.9, 98.3)

par(mfrow=c(2,2))
hist(datos)
# i) de 20 a 140 con paso 10
```

```
hist(datos, breaks = c(10), xlim = c(20,140))
# ii) de 20 a 140 con paso 5.
hist(datos, breaks = c(5), xlim = c(20,140))
# Comparar los tres histogramas obtenidos. ¿Tiene algun efecto el refinamiento de los bins?
```






2. Realice un histograma para estas observaciones utilizando puntos de corte (10, 20, 30, 40, 50, 60, 70, 80, 90, 100, 110, 120, 130). Repita corriendo el punto de inicio de los bins en 2 unidades 2 veces consecutivas. Compare los tres histogramas obtenidos. ¿Tiene algún efecto la elección del punto inicial en este ejemplo?

```
par(mfrow=c(2,2))
puntos_corte <- seq(10,130,10)
hist(datos, breaks = puntos_corte, freq = FALSE)

puntos_corte <- puntos_corte +2
hist(datos, breaks = puntos_corte, freq = FALSE)

puntos_corte <- puntos_corte +2
hist(datos, breaks = puntos_corte, freq = FALSE)
# Alerta a que es sensible el histograma? yo me quiero acercar a la densidad
# No quiero poner muy chiquitos
# El histograma parte y hace el mismo corte para todos los puntos
```



3 . Sea X la cantidad de nieve caída en un invierno en Buffalo. Implemente una función, `probab.est(x,dat,h)`, que permita estimar a $P(X \in [x - h, x + h]) = P(x - h \leq X \leq x + h)$

para cada valor x a partir de la cantidad de observaciones entre los datos disponibles `dat = (x1, . . . , xn)` que están a distancia menor o igual que h de x , siendo h el tamaño de ventana elegida.

Utilizando dicha función estime la probabilidad deseada para los valores $x = 40$ y $h = 10$. Compare con la estimación obtenida si cambia a $h = 20$.

```
# 3 probab.est(x,dat,h)
probab.est <- function(x,datos,h){
  valor<- sum(datos>=(x-h) & datos <=(x+h))
  valor/(2*h*length(datos))
}
probab.est(40,datos,10) #0.04761
```




```
## [1] 0.004761905
```

```
probab.est(40,datos,20) # 0.0055
```

```
## [1] 0.005555556
```

4 Calcule la estimación de la probabilidad definida en el ítem anterior para cada valor x de la grilla de datos observados `dat = (x1, . . . , xn)`, usando $h = 10, 20$ y 30 . Compare.

```
# 4 grilla_valores
grilla_valores <- function(datos,h){
  valores <- c()
  for (i in datos){
    valores <- c(valores,probab.est(i,datos,h)) }
  valores
}
par(mfrow=c(2,2))
plot(datos,grilla_valores(datos,10),ylab ="Ventana 10")
plot(datos,grilla_valores(datos,20),ylab ="Ventana 20")
plot(datos,grilla_valores(datos,30),ylab ="Ventana 30")
```




5 Implemente una funcion `densidad.est.parzen` que tenga por argumento un conjunto de datos `dat = (x1, . . . , xn)`, una ventana `h` y un punto `x` y devuelva `fbh(x)`, el valor de la estimacion de la densidad f en el punto x , utilizando el n'ucleo uniforme (tambi'en llamado rectangular).

```
# 5 densidad.est.parzen
densidad.est.parzen <- function(x,datos,h){
  datos <- (datos- x)/h
  valor<- sum(datos>=(-1) & datos <=(1))
  valor*1/2/(h*length(datos))
}
densidad.est.parzen(40,datos,10)
```

```
## [1] 0.004761905
```




6 Con la funcion `densidad.est.parzen` implementada, estime la densidad f en el intervalo $(25, 126.4)$ (minimo y máximo de las observaciones) sobre una grilla de 200 puntos equiespaciados para $h = 10$. Grafique el estimador $fbh(x)$ obtenido.

```
grilla_valores_parzen <- function(valoresx,datos,h){  
  # valoresx <- seq(25,126.4,length.out = 200)  
  valores <- c()  
  for (i in valoresx){  
    valores <- c(valores,densidad.est.parzen(i,datos,h)) }  
  valores  
}  
  
valoresx <- seq(25,126.4,length.out = 200)  
plot(valoresx,grilla_valores_parzen(valoresx,datos,10))
```



7 Estime la funcion de densidad f de la variable pulgadas de nieve caida en invierno a partir de los datos de Buffalo a través de la función `densidad.est.parzen` implementada en el item anterior usando $h = 10$. Realice un histograma para los datos de Buffalo y superponga la densidad estimada en los datos mediante la funcion `densidad.est.parzen` utilizando $h = 10, 20$ y 30 . Observe como varia la rugosidad de los estimadores de f obtenidos.

```
par(mfrow=c(2,2))
plot(valoresx,grilla_valores_parzen(valoresx,datos,10),ylab ="Ventana 10" )
plot(valoresx,grilla_valores_parzen(valoresx,datos,20),ylab ="Ventana 20")
plot(valoresx,grilla_valores_parzen(valoresx,datos,30),ylab ="Ventana 30")
```




8 La funcion de R density computa un estimador de la densidad a partir de un conjunto de datos $x = (x_1, \dots, x_n)$ y la evalua en un conjunto de puntos intermedios. Mediante la funcion de R density estime la funcion de densidad f de la variable pulgadas de nieve caida en invierno a partir de los datos de Buffalo y utilizando el nucleo normal, el rectangular y el de Epanechnikov con ventana $h = 5$. Realice un gráfico en el que superpone las tres estimaciones de f y compare los resultados.

```
pp.rec = density(datos,kernel = 'rectangular',window = 5)
pp.gau = density(datos,kernel = 'gaussian',window = 5)
pp.epa = density(datos,kernel = 'epanechnikov',window = 5)

plot(pp.rec)
lines(pp.rec$x,pp.rec$y,type = "l",col="black",lwd=2)
lines(pp.gau$x,pp.gau$y,type = "l",col="red",lwd=2)
lines(pp.epa$x,pp.epa$y,type = "l",col="blue",lwd=2)
```

density.default(x = datos, kernel = "rectangular", window = 5)



Dia 2

Repaso y Jugamos con: https://glmconr2.shinyapps.io/app_regre2/

con histograma:NO con densidad:SI con real:NO cambiando las ventanas a 0,25-1-4 Vecindad Si Nucleo gaussiano

con $h=0,25$ hay mucho ruido, con $h1$ hay menos ruido y se suele observar un pico unico, con $h4$ casi no hay ruido pero pierdo mi ibjeto de interes, ya estoy sesgado. $\rightarrow$ La eleccion del H es importante para: el sesgo y la varianza. YO quiero poco sesgo y varianza. Mi optimo seria encontrar una ventana que refleje lo que dicen mis datos y que haya poca varianza entre nuestros histogramas. Veremos que el n y el h se cruzan en algun punto...

—Una ventana h peque~na dar'a un estimador muy rugoso, con muchos picos y dif'icil de interpretar —una ventana h grande sobresaquista al estimador de la densidad y enmascara estructuras de los datos.

Sesgo depende del h y de la curvatura de la funcion Varianza

9. Para los datos de Buffalo halle la ventana optima h_S por la regla de Silverman para el nucleo normal, calcule la estimacion de f basada en el nucleo normal con dicha ventana y grafique la estimacion de la densidad obtenida.


```
datos = c(126.4, 82.4, 78.1, 51.1, 90.9, 76.2, 104.5, 87.4, 110.5, 25.0, 69.3, 53.5, 39.8, 63.6, 46.7, '
hsil = min((sd(datos)), (IQR(datos)/1.349))
```



```
hsil = hsil*1.06*(length(datos)**-1/5)
# hsil #0.0798

pp.gau = density(datos, kernel = 'gaussian', window = hsil)
plot(pp.gau)
lines(pp.gau$x, pp.gau$y, type = "l", col="black", lwd=2)
```

density.default(x = datos, kernel = "gaussian", window = hsil)



10. Se puede realizar la estimación de la densidad f a partir de un conjunto de datos a través de la función `density` en un punto deseado x ($\hat{f}(x)$) de la siguiente forma: $\hat{f}(x) \leftarrow \text{density}(\text{datos}, \text{from}=x, \text{to}=x, n=1)$

También mediante la función `approxfun` de R se puede aproximar la densidad estimada por la función de R `density` en el punto deseado x a partir de un conjunto de datos de la siguiente manera:

```
df <- approxfun(density(datos)) f.hat.x <- df(x)
```

Calcule la estimación de la densidad usando `density` a partir de los datos de Buffalo usando la ventana de Silverman y con esta estimación obtenga estimaciones de la densidad en los valores observados de nieve caída en Buffalo.

Grafique la densidad estimada y superponga en el mismo plot los puntos correspondientes a las observaciones y el valor estimado de la densidad correspondiente en rojo.


```
vector <- c()
for (i in datos){
  # approxfun(density(datos))
  vector <- c(vector, approxfun(density(datos, kernel = 'gaussian', window = hsil))(i))
}
```

```

}

plot(datos,vector,col="red")
lines(pp.gau$x,pp.gau$y,type = "l",col="black",lwd=2)

```




11. Llamemos $\text{fsombh}(-i)$ a la densidad estimada sin utilizar al punto x_i y usando la ventana h . Calcule las estimaciones $\text{fsombh}(-i)$ para $i = 17, 20, 51$ de la densidad f usando la función `density` a partir de los datos de Buffalo usando el núcleo de Epanechnikov y la ventana $h = 5$. Grafique en un mismo plot la estimación de f basada en todos los datos usando el núcleo de Epanechnikov y la ventana $h = 5$ y las estimaciones $\text{fsombh}(-i)$ para $i = 17, 20, 51$. Compare las estimaciones obtenidas.

```

exis <- c(17,20,51)
vector <- c()
for (i in exis){
  vector <- c(vector,approxfun(density(datos,kernel = 'epanechnikov',window = 5))(i))
}

plot(pp.gau$x,pp.gau$y,type = "l",col="black",lwd=2)
points(exis,vector,col="red",cex= 1.5)

```




12 Halle la ventana de convalidacion cruzada para la estimacion de la densidad basada en el nucleo normal utilizando los datos de Buffalo. Explore el comando `bw.ucv`.

```
# https://aakinshin.net/posts/kde-bw/  
d <- density(datos, bw = "bcv")
```

```
## Warning in bw.bcv(x): minimum occurred at one end of the range
```

```
plot(d, lwd = 2, main = "Bandwidth bcv")
```




13 Grafique en un mismo plot las estimaciones de la densidad obtenidas con el nucleo de normal usando la ventana optima obtenida en el item anterior y usando la ventana hS hallada previamente. Compare los resultados.

```
pp.gau = density(datos, kernel = 'gaussian', window = hsil)
plot(pp.gau)
# lines(pp.gau$x, pp.gau$y, type = "l", col = "black", lwd = 2)

d <- density(datos, bw = "bcv")
lines(d, lwd = 2, col = 'red')
```

density.default(x = datos, kernel = "gaussian", window = hsil)



N = 63 Bandwidth = 9.321