

29-04 Aves y Clasificacion

Parte A

Las aves parasitas de cr  a ponen huevos en nidos de otras especies (hospedador), las cuales incuban los huevos y cr  an al pichon parasito. En un bosque de talas de la provincia de Buenos Aires hay dos especies hospederas que son indistinguibles a simple vista. Una de las principales diferencias entre estas especies radica en el grado de discriminacion y remocion de huevos parasitos de sus nidos. Una de las especies es aceptadora de huevos parasitos ($Y = 0$), ya que remueve del nido solo el 30% de los huevos parasitos, mientras que la otra especie es rechazadora ($Y = 1$) ya que remueve el 80% de los huevos parasitos presentes en su nido. Adem  s, se sabe que el 90% de los nidos del bosque corresponden a la especie aceptadora, mientras que apenas el 10% restante son nidos de la especie rechazadora.

Calculo de probabilidades:

Se elige al azar un nido del bosque y se colocan $k = 8$ huevos parasitos. Denotemos con X a la variable aleatoria que indica el numero de huevos removidos del nido. Asuma que, en cada nido, la remocion (o no) de los diferentes huevos se realiza de manera independiente.

1. Calcule la probabilidad de que 5 de los huevos parasitos sean removidos del nido si se sabe que el nido parasitado es de la especie aceptadora.

```
#rechazadora y=0
py0 = 0.9
pr0 = 0.3

# aceptadora
py1 = 0.1
pr1 = 0.8 #prob de rechazar un huevo dado que soy acep

# Ej 1
dbinom(5,8,pr0)
```

```
## [1] 0.04667544
```

2. Calcule la probabilidad de que x de los huevos ajenos sean removidos del nido si se sabe que el nido parasitado es de la especie aceptadora, para 0 menor igual x menor igual 8, y represente las probabilidades calculadas en un diagrama de barras. Incluya un titulo pertinente en el grafico.

```
proba_aceptadora<-rep(0,9)
for (i in 0:8) {
  proba_aceptadora[i+1]<-dbinom(i,8,pr0)
}
```

```

huevos_removidos<-c(0,1,2,3,4,5,6,7,8)
# proba_aceptadora<-c(0.0576,0.1976,0.2965,0.2541,0.1361,0.0466,0.01,0.0647,0.00006)

df1<-data.frame(huevos_removidos,proba_aceptadora)
library(ggplot2)


```

```
## Warning: package 'ggplot2' was built under R version 4.0.5
```

```

ggplot(data = df1,
       aes(x=huevos_removidos,
           y=proba_aceptadora)) +
  geom_bar(stat = "identity", position = "stack",
          color="black") +
  coord_cartesian(ylim=c(0, 0.5),
                 xlim = c(0,8)) +
  labs(title = "Probabilidad de X entre especie aceptadora")+
  xlab("Cantidad de huevos removidos")+
  ylab("Probabilidad")

```



3. Calcule la probabilidad de que 5 de los huevos parasitos sean removidos del nido si se sabe que el nido parasitado es de la especie rechazadora.

```
dbinom(5,8,pr1)
```

```
## [1] 0.1468006
```

```
dbinom(5,8,pr1)
```


4. Calcule la probabilidad de que x de los huevos parasitos sean removidos del nido si se sabe que el nido parasitado es de la especie rechazadora, para 0 menor igual x menor igual 8, y representa las probabilidades calculadas en un diagrama de barras. Incluya un título pertinente en el gráfico.

```
proba_rechazadora<-rep(0,9)
for (i in 0:8) {
  proba_rechazadora[i+1]<-dbinom(i,8,pr1)
}

huevos_removidos<-c(0,1,2,3,4,5,6,7,8)
# proba_rechazadora<-c(0,0.00008,0.00114,0.00917,0.045875,0.1468,0.2936,0.3355,0.1677)

df2<-data.frame(huevos_removidos,proba_rechazadora)

ggplot(data = df2,
       aes(x=huevos_removidos,
           y=proba_rechazadora)) +
  geom_bar(stat = "identity", position = "stack",color="red") +
  coord_cartesian(ylim=c(0, 0.5),
                  xlim = c(0,8)) +
  labs(title = "Probabilidad de X entre especie rechazadora")+
  xlab("Cantidad de huevos removidos")+
  ylab("Probabilidad")
```



```
# Haga la tabla de la funcion de probabilidad conjunta del vector (X, Y )
df3<-data.frame(huevos_removidos,proba_aceptadora,proba_rechazadora)
```

5. Calcule la probabilidad de que 5 de los huevos parasitos sean removidos del nido.

cuaderno

```
# Cuaderno
# Y=0 Aceptador
pY0=0.90
pr0=0.30

# Y=1 Rechazador
pY1=0.10
pr1=0.80
dbinom(5,8,pr1)* pY1+ dbinom(5,8,pr0)*pY0
```

```
## [1] 0.05668796
```

6. Calcule la probabilidad de que x de los huevos parasitos sean removidos del nido, para $0 \leq x \leq 8$, y represente las probabilidades calculadas en un diagrama de barras. Incluya un titulo pertinente en el grafico.


```

#Estaria pidiendo la conjunta
# Y=0 Aceptador
pY0=0.90
pr0=0.30

# Y=1 Rechazador
pY1=0.10
pr1=0.80

palito<- c()
# palito<-dbinom(0:8,8,pr0)*pY0+dbinom(0:8,8,pr1)*pY1
# barplot(palito, names.arg=0:8, main=" Distribucion huevos rechazados")
# palito
# o bien
for (i in 1:9) palito[i]<- dbinom(i-1,8,pr1)* pY1+ dbinom(i-1,8,pr0)*pY0
barplot(palito,names.arg=0:8,main=" Distribucion huevos rechazados")

```



7. Haga la tabla de la función de probabilidad conjunta del vector (X, Y).

```

#2.
palito.Y0<- dbinom(0:8,8,pr0)

#4.

```

```
palito.Y1<- dbinom(0:8,8,pr1)
```

```
#7.
```

```
conjunta<- rbind(palito.Y0*pY0,palito.Y1*pY1)
rownames(conjunta)<- c("0", "1")
colnames(conjunta)<- c("0", "1","2", "3","4", "5","6", "7","8")
```

```
# Redondeo
```

```
tabla.conjunta<- round(conjunta,4)
sum(tabla.conjunta[1,])
```

```
## [1] 0.9
```

```
sum(tabla.conjunta[2,])
```

```
## [1] 0.1001
```

```
tabla.conjunta
```

```
##      0      1      2      3      4      5      6      7      8
## 0 0.0519 0.1779 0.2668 0.2287 0.1225 0.0420 0.0090 0.0011 0.0001
## 1 0.0000 0.0000 0.0001 0.0009 0.0046 0.0147 0.0294 0.0336 0.0168
```

Algunos datos:

El archivo depredadosclasificadas.txt contiene mediciones correspondientes a nidos elegidos al azar en el bosque, registrándose en cada uno de ellos el número de huevos parásitos removidos (primera columna) y la especie del hospedador (segunda columna), determinada mediante un análisis genético. Tenemos entonces observaciones de (X, Y) donde X indica la cantidad de huevos removidos del nido, mientras que Y = 0 si el hospedador es aceptador, Y = 1 indica que el hospedador es rechazador.

8. Calcule la proporción de hospedadores aceptadores observados en la muestra. ¿Que probabilidad esta estimando esta proporción?

```
depredado<-read.csv("depredadosclasificadas.txt", header = TRUE, sep = " ")
nrep<-length(depredado$removidos)
length(which(depredado$especie==0))/nrep
```

```
## [1] 0.896
```

9. Calcule la proporción de nidos donde se removieron x = 5 huevos parásitos entre los hospedadores aceptadores. ¿Qué probabilidad está estimando esta proporción?

```
union_acep_5<-length(which(depredado$especie==0 & depredado$removidos==5))
aceptadores<-length(which(depredado$especie==0))
union_acep_5/aceptadores
```

```
## [1] 0.04910714
```

10. Compare la funcion de probabilidad puntual condicional de X dado $Y = 0$ con la estimada, presentando ambas en un mismo grafico de barras.

```
pajaritos<-read.table("depredadosclasificadas.txt",header=T)
names(pajaritos)
```

```
## [1] "removidos" "especie"
```

```
attach(pajaritos)
mean(especie==0)
```

```
## [1] 0.896
```

```
# x removidos, y especie
#9. Estima  $P(X=5|Y=0)$ 
mean(removidos[especie==0]==5)
```


```
## [1] 0.04910714
```

```
estimada<- NULL
for (i in 1:9) estimada[i]<-mean(removidos[especie==0]==i-1)
```

```
palito.Y0<- drop(palito.Y0)
```

```
lasdos<- rbind(estimada,palito.Y0)
```

```
barplot(lasdos,names.arg=0:8,main=" ",beside=TRUE,legend=c("estimada","verdadera"),args.legend = list(x
```



11. Compare la función de probabilidad puntual condicional de X dado $Y = 1$ con la estimada, presentando ambas en un mismo gráfico de barras.

```
# x removidos, y especie
```


```
tabla<-xtabs(~ especie+removidos) # tabla de contingencia
tabla
```

```
##      removidos
## especie  0  1  2  3  4  5  6  7  8
##      0 56 178 261 215 129 44 11  2  0
##      1  0  0  0  6 15 29 23 25  6
```

```
estimada.cond.Y1<- tabla[2,]/sum(tabla[2,])
```

```
lasdos.Y1<- rbind(estimada.cond.Y1,palito.Y1)
```

```
barplot(lasdos.Y1,names.arg=0:8,main=" ",beside=TRUE,legend=c("estimada","verdadera"),args.legend = list
```



12. Hacer la tabla (con dos decimales) de las frecuencias relativas observadas de los pares (x, y) , para $0 \leq x \leq 8$, $0 \leq y \leq 1$. Indique qué valores está estimando con esta tabla.

```
tabla<-xtabs(~ especie+removidos)# tabla de contingencia
sum(tabla)
```

```
## [1] 1000
```



```
tabla<- round(tabla/sum(tabla),2)
tabla
```

```
##      removidos
## especie    0    1    2    3    4    5    6    7    8
##      0 0.06 0.18 0.26 0.22 0.13 0.04 0.01 0.00 0.00
##      1 0.00 0.00 0.00 0.01 0.01 0.03 0.02 0.03 0.01
```

Parte B

Clasificacion: Toy Example

13. Considere la regla de clasificacion que determina que un nido corresponde a la especie rechazadora ($Y = 1$) si la cantidad de huevos removidos es mayor o igual a $t = 5$. Caso contrario, determina que el nido es de la especie hospedadora aceptadora ($Y = 0$).

Implemente una funcion `regla5` que dado x , el numero de huevos agredidos, devuelva el valor 1 si $x \geq 5$, y devuelva el valor 0, caso contrario. Observe que la regla de clasificacion es una funcion g que para cada x determina un valor en $\{0, 1\}$.

Calcule R_5 , la tasa de error empirica correspondiente a esta regla, utilizando los datos de `depredadosclasificadas.txt`. Es decir, calcule la proporcion de datos mal clasificados segun esta regla.

```
datos <- read.csv('depredadosclasificadas.txt',sep=" ", header=T)

regla5 <-function(x){
  if(x >= 5){
    return (1)
  }
  else{
    return (0)
  }
}

funcion_regla5 <-function(df){
  nrep = dim(df)[1]
  lista_clasif <-rep(0,nrep)
  for (i in 1:nrep){
    if (df$especie[i] != regla5(df$removidos[i])){
      lista_clasif[i] = 1
    }
  }
  lista_clasif
}

mean(funcion_regla5(datos))
```

```
## [1] 0.078
```

14. Considere la regla de clasificaci3n que determina que un nido corresponde a la especie rechazadora ($Y = 1$) si la cantidad de huevos removidos es par. Caso contrario, determina que el nido es de un hospedador aceptador ($Y = 0$).

Implemente una funci3n rechazadorpar que dado x , el n3mero de huevos agredidos, devuelva el valor 1 si x es par, y devuelva el valor 0, caso contrario. Calcule la tasa de error emp3rica correspondiente a esta regla, utilizando los datos de depredadosclasificadas.txt. Es decir, calcule la proporci3n de datos mal clasificados seg3n esta regla.

```
rechazarpar <-function(x){
  ifelse(x%%2==0,1,0)
}

funcion_regla_par <-function(df){
  nrep = dim(df)[1]
  lista_clasif <-rep(0,nrep)
  for (i in 1:nrep){ # rechazadora 1 si es par
    if (df$especie[i] != rechazarpar(df$removidos[i])){ #1
      lista_clasif[i] = 1
    }
  }
  lista_clasif
}

mean(funcion_regla_par(datos))
```

```
## [1] 0.517
```

15. Cual de las reglas consideradas en los items anteriores (regla5 o rechazadorpar) prefiere? ¿Por que?

```
# No solo por la diferencia de criterio a nivel observador sino tambien en cuestion
# del error cuadraticom medio empirico
mean(funcion_regla5(datos))
```

```
## [1] 0.078
```

```
mean(funcion_regla_par(datos))
```

```
## [1] 0.517
```

16. Para cada $t \in \{0, \dots, 8\}$, considere la regla de clasificaci3n que determina que un nido corresponde a la variedad rechazadora ($Y = 1$) si la cantidad de huevos removidos es mayor o igual a t . Caso contrario, determina que el nido es del hospedador aceptador ($Y = 0$). Implemente una funci3n reglacorte que dados x y t , el n3mero de huevos removidos y el punto de corte, respectivamente, devuelva el valor 1 si $x \geq t$, y devuelva el valor 0, caso contrario. Calcule R_{bt} , la tasa de error emp3rica correspondiente a regla con punto de corte en t utilizando los datos depredadosclasificadas. Es decir, calcule la proporci3n de datos mal clasificados seg3n cada regla, para $0 \leq t \leq 8$.

```
reglacorte <-function(x,t){
  ifelse(x>=t,1,0)
}
```

```

funcion_regla16 <-function(df,corte){
  nrep = dim(df)[1]
  lista_clasif <-rep(0,nrep)
  for (i in 1:nrep){
    if (df$especie[i] != reglacorte(df$removidos[i], corte)){
      lista_clasif[i] = 1
    }
  }
  lista_clasif
}
funcion16 <-function(df){
  ecm <-rep(0,9)
  for (i in 0:9){
    ecm[i] = mean(funcion_regla16(datos,i))
  }
  ecm
}

```

```
funcion16(datos)
```

```
## [1] 0.840 0.662 0.401 0.192 0.078 0.063 0.075 0.098 0.104
```

```
library(ggplot2)
df
```

```

## function (x, df1, df2, ncp, log = FALSE)
## {
##   if (missing(ncp))
##     .Call(C_df, x, df1, df2, log)
##   else .Call(C_dnf, x, df1, df2, ncp, log)
## }
## <bytecode: 0x00000000215ac3a0>
## <environment: namespace:stats>


```

```

df <- data.frame(seq(0, 8, by=1),funcion16(datos))
ggplot(df) +
  aes(x = seq.0..8..by...1., y = funcion16.datos.) +
  geom_point(shape = "circle", size = 4L,
  colour = "#FF8C00") +
  geom_smooth(span = 0.71) +
  labs(x = "X", y = "ECM") +
  theme_gray()+
  scale_x_continuous(breaks = seq(0, 8, 1))

```

```
## `geom_smooth()` using method = 'loess' and formula 'y ~ x'
```



17. ¿Con qué punto de corte obtiene la regla con menor error de clasificación empírico?

18. Una regla de clasificación g puede expresarse mediante una tira de ceros y unos que indica cuanto vale g para los diferentes valores de x .

Por ejemplo, la tira $(0, 0, 0, 1, 1, 1, 0, 1, 1)$ indica que $g(0) = 0$, $g(1) = 0$, $g(2) = 0$, $g(3) = 1$, $g(4) = 1$, etc.

Implemente la función `ErrorClassTRUE` que tenga por input un vector de ceros y unos y de longitud 9 y devuelva el error de clasificación medio de la regla g , dado por $P(g(X) \neq Y)$.

```
py0 = 0.9
pr0 = 0.3
# aceptadora
py1 = 0.1
pr1 = 0.8 #prob de rechazar un huevo dado que soy acep
ErrorClassTRUE <-function(regla){
  # dbinom me da la prob de condicional si multiplico por marginal
  # luego sumo cada momento en donde da mal
  errorclastrue <- sum((regla=0)*dbinom(0:8,8,pr0)*py0)+ sum((regla=1)*dbinom(0:8,8,pr1)*py1)
  errorclastrue
}
regla <- c(0, 0, 0, 1, 1, 1, 0, 1, 1)
ErrorClassTRUE(regla)
```

```
## [1] 0.1
```

19. Calcule el error de clasificaci3n medio correspondiente a la regla con punto de corte en t , para cada $t \in \{0, \dots, 8\}$. Recuerde que si $g(X)$ es una regla de clasificaci3n, su error de clasificaci3n medio est3 dado por $P(g(X) \neq Y)$.

Grafique el error de clasificaci3n medio como funci3n de t

```
regla=rep(1,9)
ErrorMedio= rep(0,9)


for( i in 0:8){
  regla[i]<-0
  print(regla)
  ErrorMedio[i+1]=ErrorClassTRUE(regla)
}
```

```
## [1] 1 1 1 1 1 1 1 1 1
## [1] 0 1 1 1 1 1 1 1 1
## [1] 0 0 1 1 1 1 1 1 1
## [1] 0 0 0 1 1 1 1 1 1
## [1] 0 0 0 0 1 1 1 1 1
## [1] 0 0 0 0 0 1 1 1 1
## [1] 0 0 0 0 0 0 1 1 1
## [1] 0 0 0 0 0 0 0 1 1
## [1] 0 0 0 0 0 0 0 0 1
## [1] 0 0 0 0 0 0 0 0 1
```

```
# ErrorMedio
which.min(ErrorMedio)
```

```
## [1] 1
```

```
plot(0:8,ErrorMedio)
```



```
rHuevosNido<- function(ene){
  Y<- rbinom(ene,1,0.10)      # Aca sorteo el tipo de nido
  probas<- pr1*Y+pr0*(1-Y)   # hago el vector de probas asociado al tipo de nido
  X<- rbinom(ene,8,probas)    # genero la binomial de acuerdo al tipo de nido
  salida<- cbind(X,Y)
  salida
}

rHuevosNido(10)
```

20.

```
##      X Y
## [1,] 4 0
## [2,] 6 1
## [3,] 4 0
## [4,] 1 0
## [5,] 3 0
## [6,] 4 0
## [7,] 1 0
## [8,] 0 0
## [9,] 2 0
## [10,] 3 0
```