

Seguimos clasificando - Volvemos a las alturas

Clase 5

Seguimos clasificando - Volvemos a las alturas

El principal objetivo de esta guía es afianzar los contenidos de clasificación e integrarlos con conocimientos y trabajos prácticos previos: vamos a mezclar todo en la coctelera!

Para eso, vamos a volver a nuestro primer amor: los datos de alturas. En este caso la idea es predecir a partir del dato de altura de un individuo su género implementando distintos plug-in en la regla óptima de Bayes.


Te recordamos que en esta página podrás acceder nuevamente a los datos de alturas que generaste en un TP anterior y que vas a utilizar para resolver esta guía. La idea sigue siendo que cada uno trabaje con sus propios datos y por eso les pedimos que ingresen un número de identificación, ya sea el número de libreta o los 5 últimos del DNI para obtener datos de forma personalizada.

1. Descargar de esta página un conjunto de $n = 500$ observaciones, con todas las variables y leer el archivo en R. Trabajaremos con las variables altura y género (codificada como F o M). Graficar un plot que pueda dar información sobre la relación entre estas dos variables.

```
datos <- read.csv('alturas_identificacion_42414_n_500.csv', sep=";", header=T)
library(ggplot2)
```

```
## Warning: package 'ggplot2' was built under R version 4.0.5
```

```
ggplot(datos) +
  aes(x = genero, y = altura, fill = genero, colour = genero) +
  geom_boxplot() +
  scale_fill_hue(direction = 1) +
  scale_color_hue(direction = 1) +
  theme_bw()
```



2.

2. Con la regla de la mayoría vamos a aprender a clasificar el genero de un individuo como femenino (1) o masculino (0) cuando su altura $x = 165$ mediante el *metodo de vecinos*. Para ello, considerar los $k = 10$ vecinos mas cercanos y calcular la proporcion de 1's. Segun este resultado, ¿como clasificarias al genero de un nuevo individuo con altura igual a 165 cm, F o M? Repetir con $x = 175$.

```
##### 1.2 KNN
promedio_vecinos <-function(datos,xnew, vecinos_cantidad ){
  df <- data.frame(datos$altura,datos$genero)
  df$datos.altura
  df$resta = abs(df$datos.altura-xnew) # Resta con valor ingresado de todas las alturas
  df <- df[order(df$resta),c(1,2,3)] # Ordeno el df
  df
  genero <- df[1:vecinos_cantidad,2] # Creo vector con los generos de los KNN vecinos mas cercanos
  prop <- sum(genero == "F")/ vecinos_cantidad
  prop
}
promedio_vecinos(datos,165, 100)
```

```
## [1] 0.69
```

```
clasifico_vecinos <-function(datos,altura,vecinos){
  ifelse(promedio_vecinos(datos,altura, vecinos)>0.5,1,0) # 1 es F, 0 es M
```

```
}
clasifico_vecinos(datos,165, 10)
```

```
## [1] 1
```

3. Con la regla de la mayoría vamos a aprender a clasificar el género de un individuo como femenino (1) o masculino (0) cuando su altura $x = 165$ mediante el método de *promedios móviles*. Para ello, considerar una ventana de tamaño $h = 1,5$ alrededor del punto de interés y calcular la proporción de 1's. Según este resultado, ¿cómo clasificarías al género de un nuevo individuo con altura igual a 165 cm, F o M? Repetir con $x = 175$.

```
##### 1.3 MOVIL
promedio_movil <-function(datos,alturanueva,ventana){
  prom_movil = datos[datos$altura>(alturanueva-ventana) & datos$altura<(alturanueva+ventana),]
  prop <- sum(prom_movil$genero == "F")/ dim(prom_movil)[1]
  prop
}
ventana = 1.5
altura = 165
promedio_movil(datos,altura,ventana)
```

```
## [1] 0.7894737
```

```
clasifico_movil <-function(datos,altura,vecinos){
  ifelse(promedio_movil(datos,altura, vecinos)>0.5,1,0) # 1 es F, 0 es M
}
clasifico_movil(datos,165, 10)
```

```
## [1] 1
```

2

Funciones

4. Clasificar el género de un individuo en F o M conociendo su altura mediante la regla de la mayoría utilizando el método de vecinos más cercanos. Para ello, implementar la función ClasificoVecinos(X, Y, xNuevo, k=10) que tenga por input un conjunto de valores de X, sus correspondientes valores de Y, un nuevo valor x para el que se quiere realizar la clasificación y la cantidad $k = 10$ de vecinos que vamos a utilizar para calcular la regla de la mayoría. (...por ahora te damos el k...)

```
##### 2.4 VECINOS
ClasificoVecinos <- function(datos,alturanueva,ventana){
  promedio_vecinos(datos,alturanueva, ventana)
  clasifico_vecinos(datos,alturanueva, ventana)
}

ClasificoVecinos(datos,169,10)
```

```
## [1] 0
```

5. Clasificar el genero de un individuo en F o M conociendo su altura mediante la regla de la mayoría utilizando el método de promedios móviles. Para ello, implementar la función ClasificoMovil(X, Y, xNuevo, h=1) que tenga por input un conjunto de valores de X, sus correspondientes valores de Y, un nuevo valor x para el que se quiere realizar la clasificación y una ventana h = 1 para calcular la regla de la mayoría. (...por ahora te damos la ventana h...)

```
##### 2.5 MOVIL
ClasificoMovil <- function(datos,alturanueva,ventana){
  promedio_movil(datos,alturanueva, ventana)
  clasifico_movil(datos,alturanueva, ventana)
}

ClasificoMovil(datos,169,1.5)
```

```
## [1] 0
```

3.


El aditivo aromático: Regla óptima de Bayes - Método Generativo.

Recordemos que cuando la covariable es una variable continua la regla de Bayes óptima puede escribirse como: $gop(x) = 1$ si $f_1(x)P(Y = 1) > f_0(x)P(Y = 0)$ 0 si c. c. donde $X|Y = 0 \sim f_0$ y $X|Y = 1 \sim f_1$ son las densidades condicionales. Como hemos mencionado en clase, en los métodos generativos la regla de Bayes se implementa en la práctica estimando las densidades f_0 y f_1 y la probabilidad $P(Y = 1)$.

6. Volvamos a la Guía de Predicciones (clase 13/04) ítems 6 y 7, donde se realizó un histograma de alturas para cada género y se le superpuso una curva a cada uno de ellos. ¿Qué curva se le superpuso a cada histograma? ¿Con qué parámetros? Realizar nuevamente los histogramas de alturas para cada sexo y a cada uno de ellos superponerle la curva como en la Guía 7. ¿Qué relación guardan estas curvas con las densidades f_0 y f_1 ?


```
##### 3.6
hist(datos$altura, )
```

Histogram of datos\$altura




```
library(ggplot2)
masc = datos[datos$genero=="M",]
hist(masc$altura , probability = TRUE)
lines(density(masc$altura), col="blue", lwd=2)
```

Histogram of masc\$altura



```
fem = datos[datos$genero=="F",]  
hist(fem$altura , probability = TRUE)  
lines(density(fem$altura), col="pink", lwd=2)
```



7. ¿Cual es la proporción de individuos de género femenino en tu conjunto de datos? ¿Como estimarias $P(Y = 1)$ a partir de tus datos? ¿Cuánto te da la estimación propuesta?

```
##### 3.7
prop_fem <- sum(datos$genero == "F") / dim(datos)[1]
prop_fem
```

```
## [1] 0.506
```

8. Haciendo un plug-in en $gop(x)$ con las estimaciones de $f_1(x)$, $f_0(x)$, $P(Y = 1)$ y $P(Y = 0)$, vamos a aprender a clasificar el género de un individuo como femenino (1) o masculino (0) cuando su altura $x = 165$. Usando el método generativo con tus datos, ¿cómo clasificarías a alguien nuevo con altura igual a 165 cm, F o M? Repetir el ítem anterior para $x = 175$.

9. Clasificar el género de un individuo en F o M conociendo su altura mediante el método generativo. Para ello, implementar la función `ClasificoGenerativo(X, Y, xNuevo)` que tenga por input un conjunto de valores de X, sus correspondientes valores de Y, un nuevo valor x para el que se quiere realizar la clasificación.

```
##### 3.8 y 9
# Probando código
prop_fem <- sum(datos$genero == "F") / dim(datos)[1]
prop_fem
```

```
## [1] 0.506
```

```
mean(fem$altura)
```

```
## [1] 159.2917
```

```
var(fem$altura)
```

```
## [1] 7.511955
```

```
dnorm(150,mean(fem$altura),var(fem$altura))
```

```
## [1] 0.0247131
```

```
# Funcion
```

```
plugin <-function(datos,alturanueva){  
  fem = datos[datos$genero=="F",]  
  masc = datos[datos$genero=="M",]  
  propfem = sum(datos$genero == "F") / dim(datos)[1]  
  propmasc = sum(datos$genero == "M") / dim(datos)[1]  
  ifelse( (dnorm(alturanueva,mean(fem$altura),var(fem$altura))*prop_fem) >= (dnorm(alturanueva,mean(masc$altura),var(masc$altura))*prop_masc),  
  }  
}
```

```
plugin(datos,166) # 1 es mujer
```

```
## [1] 1
```

5.

Bonus Track

Leyendo el fondo de la copa... 11. Graficar xNuevo (en el eje de abscisas) tomando valores entre 160 y 170 con un paso de 0.01 y en el de ordenadas el valor con el que clasifica a cada valor la regla ClasificoVecinos que implementaste con tus datos (sugerimos representar con linea). Interpretar el criterio con el que clasifica esta regla. 12. Repetir el ítem anterior con ClasificoMovil y ClasificoGenerativo y superponer con otro color al gráfico anterior. Interpretar y comparar el criterio con el que clasifica cada regla.

```
##### 5
```

```
test <- read.csv('alturas.testeo.csv',sep=",", header=T)
```

```
ClasificoVecinos(datos,166,10)
```

```
## [1] 0
```

```
ClasificoMovil(datos,166,1.5)
```

```
## [1] 0
```

```
plugin(datos, 166)
```

```
## [1] 1
```

```
# funcion_testeo <-function(df){
nrep = dim(test)[1]
lista_clasif_knn <-rep(NA,nrep)
lista_clasif_movil <-rep(NA,nrep)
lista_clasif_plug <-rep(NA,nrep)


for (i in 1:nrep){ # rechazadora 1 si es par
  # print(test$altura[i])
  lista_clasif_knn[i] = ClasificoVecinos(test,test$altura[i],10)
  # print(lista_clasif_knn[i])
  lista_clasif_movil[i] = ClasificoMovil(test,test$altura[i],1.5)
  # print(lista_clasif_movil[i])
  lista_clasif_plug[i] = plugin(test,test$altura[i])
}

# return(lista_clasif_knn,lista_clasif_movil,lista_clasif_plug)
# }

# a,b,c = funcion_testeo(test)
test$genero2 = ifelse(test$genero == "F",1,0)
test$genero2 = as.factor(test$genero2)
dfgraficar <- data.frame(test$altura,test$genero2,
                        lista_clasif_knn,lista_clasif_movil,lista_clasif_plug)

dfgraficar$lista_clasif_knn = as.factor(dfgraficar$lista_clasif_knn)
dfgraficar$lista_clasif_movil = as.factor(dfgraficar$lista_clasif_movil)
dfgraficar$lista_clasif_plug = as.factor(dfgraficar$lista_clasif_plug)

ggplot(dfgraficar, aes(test.altura)) + # basic graphical object
  geom_point(aes(y= test.genero2), colour="green",shape=15) + # first layer
  geom_point(aes(y= lista_clasif_knn), colour="red",position = position_dodge2(w = 0.1))+ # second layer
  geom_point(aes(y= lista_clasif_movil), colour="orange",position = position_dodge2(w = 0.2))+ # second layer
  geom_point(aes(y= lista_clasif_plug), colour="blue",position = position_dodge2(w = 0.3))+ # second layer
  scale_color_manual(values = c("Women" = "blue", 'Men' = '#3399ff')) +
  scale_shape_manual(values = c('Women' = 17, 'Men' = 16))
```



4.

A batir!

10. Ahora vamos a testear las reglas. En el archivo `alturas.testeo.csv` se encuentran 31 datos de altura que separamos para testear como funcionan los tres métodos implementados. Para ello, aplicar a este conjunto de datos cada una de las tres reglas implementadas en los ítems anteriores, calcular el Error de Clasificación Empírico de cada clasificador sobre estos datos. ¿Cuál de ellas te parece que clasifica mejor?

```
##### ECM de cada metodo
funcion_contar_errores <-function(df){
  nrep = dim(df)[1]
  lista_clasif_knns <-rep(0,nrep)
  lista_clasif_movils <-rep(0,nrep)
  lista_clasif_plugs <-rep(0,nrep)

  for (i in 1:nrep){
    if (df$test.genero2[i] != df$lista_clasif_knn[i]){
      lista_clasif_knns[i] = 1
    }
    if (df$test.genero2[i] != df$lista_clasif_movil[i]){
      lista_clasif_movils[i] = 1
    }
    if (df$test.genero2[i] != df$lista_clasif_plug[i]){

```

```

        lista_clasif_plugs[i] = 1
    }

}
print("Errores knn ")
print(sum(lista_clasif_knns))

print("Errores movil ")
print(sum(lista_clasif_movils))

print("Errores plug ")
print(sum(lista_clasif_plugs))
}

funcion_contar_errores(dfgraficar)

```

```

## [1] "Errores knn "
## [1] 1
## [1] "Errores movil "
## [1] 1
## [1] "Errores plug "
## [1] 2

```