

Simulaciones Cuantiles

Repaso

Finalmente, empezamos a hablar de estadística. De estimación, de datos.

Repasemos brevemente el marco teórico bajo el cual estamos trabajando:

- Para nosotros población es la distribución que genera los datos.
- Muestra: $X_1, \dots, X_n$ iid, $X_i \sim F$, F es la población.
- Cualquier cantidad $\theta = \theta(F)$ relacionada a F se dice parámetro poblacional.
- Cuando hacemos estadística no conocemos a F ni al valor del parámetro poblacional de interés.
- Cuando hacemos estadística queremos hacer una cuenta con la muestra que nos permita estimar el valor de interés.

Estimador: $\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n)$ Estimación: $\hat{\theta}_n^{\text{obs}} = \hat{\theta}_n(x_1, \dots, x_n)$, donde $x_1, \dots, x_n$ representan datos. Valores observados. Notemos que:

- el estimador $\hat{\theta}_n$ ES UNA NUEVA VARIABLE ALEATORIA (a cada uno le da otra cosa)
- la estimación $\hat{\theta}_n^{\text{obs}}$ es un número: una realización del estimador. El resultado que obtengo con MIS datos.
- el estimador $\hat{\theta}_n$, por ser una variable aleatoria, tiene SU PROPIA distribución, su propia esperanza, varianza y todo lo que se le pueda pedir a una variable aleatoria.

Algunas definiciones importantes:

- Consistencia: $(\hat{\theta}_n)_{n=1}^\infty$ se dice consistente si $\hat{\theta}_n \rightarrow \theta$ en probabilidad. Esta propiedad, por lo general, la podemos deducir combinando la Ley de los Grandes Números con alguna otra propiedad.
- Sesgo: El sesgo de un estimador se define como $E(\hat{\theta}_n) - \theta$. Cuando un estimador es promedio de algo, resulta fácil calcular su esperanza. Si no...

Gracias a la Ley de los Grandes Números y otras yerbas, hemos estudiado propiedades de los estimadores propuestos para μ , para una probabilidad p y para σ^2 .

Estimadores que son promedio.

Si el estimador es $\hat{\theta}_n = \text{promedio de mongo}$, ocurren dos cosas importantes:

- Conocemos la esperanza del estimador: $E(\hat{\theta}_n) = E(\text{mongo})$, por propiedad de linealidad de la esperanza.
- Además, de la Ley de los Grandes Números, sabemos que el $\hat{\theta}_n$ que es el promedio de mongo converge a la esperanza de mongo. Es decir, el estimador es consistente si $\hat{\theta}_n \rightarrow E(\text{mongo})$, en cuyo caso también resulta insesgado.
- Si mongo de i son i.i.d. y con distribución normal, la distribución de $\hat{\theta}_n$ también es normal: promedio de normales ES normal.

- Si x_i son i.i.d. y n es grande, en muchas circunstancias podemos decir que la distribución de $\bar{x}_n$ es APROXIMADAMENTE normal, gracias al Teorema Central del Límite.

Hemos estado estudiando la convergencia del promedio en distintos sentidos: en probabilidad que resulta de la Ley de los Grandes Números y en distribución que resulta del Teorema Central del Límite, ambos juegan un rol fundamental en la Estadística.

Ahora la pregunta es: ¿Cómo se comportan los cuantiles muestrales y su distribución? No tenemos propiedades que garanticen la consistencia de los cuantiles muestrales a los poblacionales. En esta Guía vamos a estudiar mediante una simulación el comportamiento de los cuantiles muestrales, a medida que n aumenta. Esperamos ver que convergen a donde queremos (¡los cuantiles poblacionales!).

Consistencia de los cuantiles muestrales o empíricos

Distribución Uniforme

Sean $X_i \sim U(a, b)$ siendo $a = 67$ y $b = 73$. Utilizaremos X para denotar de manera genérica una variable con esta misma distribución.

Cuantiles poblacionales vs. muestrales o empíricos

1. ¿Cuanto vale $q_{0.9} = F^{-1}(0.9)$?


```
#Cuantil poblacional. Se puede calcular matematicamente o con comando en R
a<-67
b<-73
p<-0.9
cuantil_90<-(b*p)+(a*(1-p)) #72.4
cuantil_902<-qunif(0.9,a,b) #72.4
```

2. Guardar en el vector muchas uniformes, $N_{rep} = 1000$ datos con distribución $U(a, b)$ siendo $a = 67$ y $b = 73$, utilizando el comando `runif()`.

```
Nrep<-1000
muchas_uniformes<-runif(Nrep,67,73)
```


3. Guardar en el vector muchos cuantiles uniformes los cuantiles muestrales correspondientes a las primeras n observaciones del vector muchas uniformes, con $n = 1, \dots, N_{rep}$. Explorar el comando `quantile(x=, probs=)`.
4. Graficar n (en el eje x) versus el cuantil empírico de los primeros n datos. Utilizar `ylim=c(65,75)`.

```
muchos_cuantiles_uniformes<-rep(NA,Nrep)
for (i in 1:Nrep) {
  muchos_cuantiles_uniformes[i]<-quantile(muchas_uniformes[0:i],probs = 0.9)
}
plot(1:Nrep,muchos_cuantiles_uniformes,ylim = c(65,75))
```



5. Repetir los items 2 a 4 Ngen = 10 veces, agregando al grafico anterior los cuantiles de cada individuo en un color diferente.

```
Ngen<-10
for (j in 1:Ngen) {
  muchas_uniformes<-runif(Nrep,67,73)
  muchos_cuantiles_uniformes<-rep(NA,Nrep)
  for (i in 1:Nrep){
    muchos_cuantiles_uniformes[i]<-quantile(muchas_uniformes[1:i],probs=0.9)
  }
  if(j==1){plot(1:Nrep, muchos_cuantiles_uniformes,ylim = c(65,75))}
  else{
    points(1:i,muchos_cuantiles_uniformes,ylim = c(65,75), col=j)
  }
}
```



6. Indicar cual espera que sea el valor limite de estas sucesiones. ¿Se condice con lo que muestra el grafico?
Los cuantiles convergen a los cuantiles poblacionales.

Distribucion Normal

Sean $X_i \sim N(\mu, \sigma^2)$ siendo $\mu = 70$, $\sigma^2 = 1.2$. Utilizaremos X para denotar de manera generica una variable con esta misma distribucion.

Cuantiles poblacionales vs. muestrales o empiricos

1. ¿Cuanto vale $q_{0.9} = F^{-1}(0.9)$?

```
#Cuantil poblacional
mu<-70
sd<-sqrt(1.2)
cuantil_normal0.9<-qnorm(0.9,mu,sd) #71.403
```


2. Guardar en el vector muchas normales, $Nrep = 1000$ datos con distribución $N(\mu, \sigma^2)$ siendo $\mu = 70$ y $\sigma^2 = 1.2$, utilizando el comando `rnorm()`.

```
muchas_normales<-rnorm(Nrep,mu,sd)
```

3. Guardar en el vector muchos cuantiles normales el cuantil empirico de las primeras n observaciones del vector muchas normales, con $n = 1, \dots, Nrep$.


4. Graficar n (en el eje x) versus el cuantil empírico de los primeros n datos. Utilizar $ylim=c(60,80)$.

```
muchos_cuantiles_normales<-rep(NA,Nrep)
for (i in 1:Nrep) {
  muchos_cuantiles_normales[i]<-quantile(muchas_normales[1:i],probs = 0.9)
}
plot(1:Nrep,muchos_cuantiles_normales,ylim = c(60,80))
```



5. Repetir los items 2 a 4 $N_{gen} = 10$ veces, agregando al gráfico anterior los cuantiles de cada individuo en un color diferente.

```
Ngen<-10
for (j in 1:Ngen) {
  muchas_normales<-rnorm(Nrep,mu,sd)
  muchos_cuantiles_normales<-rep(NA,Nrep)
  for (i in 1:Nrep) {
    muchos_cuantiles_normales[i]<-quantile(muchas_normales[1:i],probs = 0.9)
  }
  if(j==1){plot(1:Nrep, muchos_cuantiles_normales,ylim = c(60,80))}
  else{
    points(1:i,muchos_cuantiles_normales,ylim = c(60,80), col=j)
  }
}
```



6. Indicar cual espera que sea el valor limite de estas sucesiones. ¿Se condice con lo que muestra el grafico? Idem antes.

Distribucion Exponencial

Sean $X_i \sim E(\lambda)$ siendo $\lambda = 1/10$. Utilizaremos X para denotar de manera generica una variable con esta misma distribucion.

Cuantiles poblacionales vs. muestrales (o empiricos)

1. ¿Cuanto vale $q_{0.9} = F^{-1}(0.9)$?

```
#Cuantil poblacional
cuantil_exp0.9<-qexp(0.9,0.1) #23.0258
```

2. Guardar en el vector muchas exponenciales, $Nrep = 1000$ datos con distribucion $E(\lambda)$ siendo $\lambda = 1/10$, utilizando el comando `rexp()`.


```
Nrep<-1000
muchas_exp<-rexp(Nrep,0.1)
```

3. Guardar en el vector muchos cuantiles exponenciales el cuantil muestral de las primeras n observaciones del vector muchas exponenciales, con $n = 1, \dots, Nrep$.
4. Graficar n (en el eje x) versus el cuantil muestral de los primeros n datos. Utilizar `ylim=c(0,35)`.

```

muchos_cuantiles_exp<-rep(NA,Nrep)
for (i in 1:Nrep){
  muchos_cuantiles_exp[i]<-quantile(muchas_exp[1:i],probs = 0.9)
}
plot(1:i,muchos_cuantiles_exp, ylim = c(0,35))

```




5. Repetir los items 2 a 4 Ngen = 10 veces, agregando al gráfico anterior los cuantiles de cada individuo en un color diferente.

```

Ngen<-10
for (j in 1:Ngen) {
  muchas_exp<-rexp(Nrep,0.1)
  muchos_cuantiles_exp<-rep(NA,Nrep)
  for (i in 1:Nrep){
    muchos_cuantiles_exp[i]<-quantile(muchas_exp[1:i],probs = 0.9)
  }
  if(j==1){plot(1:Nrep, muchos_cuantiles_exp,ylim = c(0,35))}
  else{
    points(1:i,muchos_cuantiles_exp,ylim = c(0,35), col=j)
  }
}

```



6. Indicar cual espera que sea el valor limite de estas sucesiones. ¿Se condice con lo que muestra el grafico?

Histogramas


Para cada uno de los modelos contemplados, realizar histogramas basados en $N_{gen} = 100$ replicas, considerando muestras de tamaño $n=5$, $n=30$, $n=100$.

Para simplificar, solo lo haremos para el modelo exp.

$n=5$

```
lambda<-0.1
n=5
Ngen<- 100
empi_dist_q<-rep(NA, Ngen)
for (i in 1:Ngen){
  mis_exponenciales <- rexp(n,lambda)
  empi_dist_q[i]<- quantile(mis_exponenciales, 0.9)
}

hist(empi_dist_q, probability=TRUE)
```





```
### n=30
```

```
lambda<-0.1
n=30
Ngen<- 100
empi_dist_q<-rep(NA, Ngen)
for (i in 1:Ngen){
  mis_exponenciales <- rexp(n,lambda)
  empi_dist_q[i]<- quantile(mis_exponenciales, 0.9)
}

hist(empi_dist_q, probability=TRUE)
```

Histogram of empi_dist_q



```
### n=100
```

```
lambda<-0.1
n=100
Ngen<- 100
empi_dist_q<-rep(NA, Ngen)
for (i in 1:Ngen){
  mis_exponenciales <- rexp(n,lambda)
  empi_dist_q[i]<- quantile(mis_exponenciales, 0.9)
}

hist(empi_dist_q, probability=TRUE)
```

